

2 Referencial Teórico

2.1 Visão Computacional

O advento da Visão Computacional e do Processamento Digital de Imagens (PDI) tem revolucionado diversos processos industriais e desportivos através de métodos robustos de automação visual. Embora compartilhem bases teóricas, as duas áreas possuem definições e fronteiras funcionais bem delimitadas na literatura clássica. Conforme Barelli (2018), o Processamento Digital de Imagens consiste na aplicação de algoritmos computacionais para transformar e manipular imagens digitais (entrando com uma imagem e gerando uma imagem modificada como saída, por exemplo, por meio de realce de bordas ou remoção de ruídos). Em contrapartida, a Visão Computacional busca emular as funções cognitivas da visão humana por meio de hardware e software, interpretando a informação presente nas imagens digitais para extrair características e tomar decisões automatizadas de alto nível.

Usualmente, um sistema robusto baseado em Visão Computacional opera sob um fluxo estruturado, composto sequencialmente por essa ordem: (a) Aquisição da Imagem, obtida por meio de sensores que digitalizam os sinais luminosos; (b) Pré-processamento, voltado ao tratamento de perturbações e destaque das bordas; (c) Segmentação, etapa responsável por separar os objetos de interesse do segundo plano; (d) Extração de Atributos, que computa medidas físicas ou geométricas relevantes; e (e) Reconhecimento e Decisão de Alto Nível, que valida e classifica o objeto para gerar a saída final desejada (BARELLI, 2018).

A aquisição de imagens é realizada através de sensores fotoelétricos integrados à câmera, como os sensores CCD (Charge Coupled Device) e CMOS (Complementary Metal-Oxide Semiconductor). Ambos funcionam convertendo radiação luminosa analógica em elétrons por meio de uma matriz de capacitores fotossensíveis, usando um conversor analógico-digital (A/D) para discretizar a tensão elétrica gerada e transformá-la em valores binários (pixels) dispostos em coordenadas de linha e coluna (GONZALEZ; WOODS, 2006). Contudo, no momento da captura, a imagem analógica original é afetada por ruídos de várias origens, incluindo poeira em suspensão, vibrações térmicas da câmera, iluminação irregular e flutuações elétricas do próprio circuito integrado do sensor (BARELLI, 2018).

Diante desse panorama, torna-se imperativo aplicar filtros lineares ou não lineares de suavização espacial durante a etapa de pré-processamento, visando atenuar variações de alta frequência associadas ao ruído. Um dos operadores mais eficientes é o Filtro Gaussiano, cuja função de transferência espacial é descrita por uma distri-

buição gaussiana bidimensional. Sua aplicação equivale a uma convolução espacial que atenua o ruído mantendo a transição gradual dos contornos das formas físicas na imagem. Segundo Gonzalez e Woods (2006), a suavização gaussiana é particularmente útil antes de algoritmos de detecção de gradiente (como o de Canny), pois reduz a detecção de falsas bordas geradas por flutuações eletrônicas locais de intensidade cromática.

2.2 Métodos Fundamentais de Segmentação de Objetos e Detecção de Bordas

A segmentação é considerada uma das etapas cruciais em Visão Computacional, pois a eficiência de todas as análises subsequentes depende do correto isolamento das regiões ou formas de interesse. Conforme clássicos do processamento de imagens (GONZALEZ; WOODS, 2006), não existe uma abordagem universal para esta tarefa; trata-se de um processo de ajuste empírico e adaptativo às propriedades físicas da cena capturada. Dentre as técnicas fundamentais, destacam-se a segmentação por binarização (thresholding) e a segmentação baseada em bordas.

A binarização clássica converte uma imagem em escala de cinza em preto e branco com base em um limiar (threshold) de intensidade. Embora o limiar possa ser fixado de forma empírica, técnicas como a binarização adaptativa e o método de Otsu automatizam o cálculo do ponto de corte matemático. O algoritmo de Otsu funciona analisando estatisticamente o histograma bimodal da imagem e determinando o limiar ideal de forma a minimizar a variância intra-classe entre os pixels pertencentes ao objeto e os pixels pertencentes ao fundo da cena (GONZALEZ; WOODS, 2006). Por sua vez, a segmentação por contorno busca detectar discontinuidades locais bruscas na intensidade cinza dos pixels vizinhos. A detecção de bordas baseia-se no cálculo do gradiente local, que representa a primeira derivada da imagem. Operadores como Sobel e Laplacian mapeiam a direção e a força da mudança de contraste local (GONZALEZ; WOODS, 2006). Como refinamento, o Detector de Bordas de Canny destaca-se por ser uma abordagem multifásica altamente eficiente. O pipeline de Canny inclui: (1) suavização da imagem via filtro gaussiano; (2) cálculo do mapa de gradiente com o operador Sobel; (3) aplicação de supressão de não-máximos para afinar as bordas largas identificadas; e (4) limiarização por histerese, que utiliza dois limiares distintos (baixo e alto) para interligar bordas fracas a bordas fortes, atenuando discontinuidades de contorno causadas por ruídos e oclusões espaciais (BARELLI, 2018).

2.3 Morfologia Matemática e Tratamento de Ruídos de Binarização

O resultado obtido diretamente após o processo de binarização frequentemente apresenta imperfeições, como buracos internos ou pequenos agrupamentos de pixels isolados que representam ruídos residuais da cena. Para retificar esses desvios físicos, a Morfologia Matemática fornece uma ferramenta teórica de alto desempenho baseada na Teoria dos Conjuntos. Os operadores morfológicos modificam a forma e a conectividade estrutural dos objetos de interesse por meio de uma forma de prova geométrica conhecida como Elemento Estruturante (retangular, elíptico ou em formato de cruz), que varre a imagem de entrada atuando sobre a vizinhança dos pixels (GONZALEZ; WOODS, 2006).

2.4 Redes Neurais Convolucionais e Arquitetura YOLOv8 para Detecção de Objetos

Diferente das abordagens clássicas de binarização e morfologia matemática que dependem de calibrações manuais de limiarização e são altamente suscetíveis a variações ambientais de iluminação externa, o estado da arte do reconhecimento de objetos baseia-se em redes convolutivas profundas (ConvNets ou CNNs). As CNNs utilizam operações matemáticas de multiplicação de matrizes por meio de kernels de convolução empilhados para extrair de forma automática atributos espaciais complexos em diferentes níveis de abstração (IBM, 2026).

Para processamento de vídeo em tempo real, destaca-se a arquitetura YOLOv8 (You Only Look Once v8), desenvolvida por Glenn Jocher da empresa Ultralytics. A YOLOv8 introduz avanços expressivos em relação às versões anteriores: (a) substituição do módulo C3 pelo mais moderno módulo C2f (composto por duas convoluções), que otimiza e simplifica o fluxo de gradiente através do gargalo de programação CSP, reduzindo o custo computacional e mantendo alta precisão; (b) adoção de uma cabeça de detecção desacoplada (decoupled head), onde as tarefas de classificação e predição das coordenadas das caixas delimitadoras são tratadas de forma independente através de redes distintas; e (c) ausência de âncoras (anchor-free detector), prevendo diretamente as caixas sem depender de proporções de aspecto pré-calculadas (ADAM et al., 2025). Tais modificações otimizam consideravelmente tanto a velocidade de inferência (latência na escala de milissegundos) quanto o percentual de acerto estatístico.

2.5 Extração de Características de Contornos e Estimativa Euclidiana do Escore

Após o processamento visual e inferência pela rede neural convolutiva profunda para obter as regiões de interesse (bounding boxes), o sistema necessita extrair atributos geométricos e dimensionais do impacto da flecha. Para o isolamento preciso das formas em nível de pixel, aplica-se a técnica de extração de contornos do OpenCV via rotina `cv2.findContours`. A rotina funciona varrendo os limites do objeto binarizado e retornando uma lista ordenada de coordenadas espaciais correspondentes às bordas do objeto de interesse.

Para reduzir o uso excessivo de memória em sistemas embarcados de processamento na borda (edge), utiliza-se o método de aproximação de contorno `CHAIN_APPROX_SIMPLE`. Esse método de compressão descarta todos os pontos intermediários redundantes ao longo de segmentos de linha horizontais, verticais ou diagonais, preservando apenas os pontos finais geométricos das arestas (BARELLI, 2018). Na sequência, para determinar com precisão subpixel o centro geométrico (cx, cy) do local de impacto, calcula-se o centroide do contorno por meio do método matemático dos Momentos de Imagem (`cv2.moments`), aplicando as relações estritas baseadas na Equação de Momentos de ordem zero e ordem um (BARELLI, 2018).

Uma vez obtido o centro geométrico da flecha detectada e tendo como referência fixa o centro exato do alvo real, a pontuação desportiva é calculada instantaneamente na unidade pós-processamento utilizando a Distância Euclidiana Bidimensional. A pontuação oficial no tiro com arco regulamentado pela FITA baseia-se puramente em zonas de anéis circulares concêntricos ao centro geométrico. Portanto, o mapeamento do escore final é dado pela distância linear escalar calculada pela clássica Equação de Distância Euclidiana:

$$d = \sqrt{(x_f - x_c)^2 + (y_f - y_c)^2}$$

onde (x_f, y_f) denota a coordenada central da ponta da flecha calculada pelos momentos de imagem e (x_c, y_c) corresponde à coordenada central fixa calibrada do alvo real. Esta operação geométrica apresenta custo computacional desprezível, rodando em microssegundos no hardware embarcado. O escore é então classificado de 1 a 10 através da comparação direta da distância escalar com o raio das zonas circulares guias virtuais projetadas conforme as normas e diâmetros internacionais da FITA (ADAM et al., 2025).